

Paso 04 · Marts — el star schema

De candidatos crudos a un modelo dimensional consultable — con dbt

Mathias Berg · Stuttgart · 2026-09-20 · Repo: github.com/mberger/jazz-standards-analytics

01 Qué construimos y por qué

Staging (paso 03) dejó los datos limpios pero todavía crudos: cada búsqueda de Spotify trajo grabaciones **candidatas**, con dos problemas — **falsos positivos** (temas que solo comparten el título) y **duplicados** (remasters, recopilatorios, reediciones del mismo tema). El paso 04 los resuelve en dos capas:

- **Intermediate** — resuelve la identidad (¿este candidato es realmente el standard?) y deduplica.
- **Marts** — arma el **star schema**: una tabla de hechos rodeada de dimensiones, lista para el dashboard.

02 Intermediate: entity resolution

La búsqueda por título trae ruido: "Summertime Sadness" (Lana Del Rey) no es "Summertime"; "Easy Livin'" (Uriah Heep) no es "Easy Living". La resolución normaliza el título del track y lo compara con el del standard, quedándose solo con los que coinciden:

```
-- int_recordings_resolved.sql
select ...
from recordings r
join standards s on r.standard_id = s.standard_id
where {{ normalize_title('r.track_name') }}
      = {{ normalize_title('s.title') }}
```

La normalización vive en un **macro reutilizable**, `normalize_title`: minúsculas, saca paréntesis, sufijos ("Live", "- Remastered") y puntuación.

```
"Lover Man (Oh, Where Can You Be?) - Live"    -> "lover man"
"Body & Soul (feat. Biig Piig)"                 -> "body soul"
```

03 Intermediate: deduplicación

Un mismo artista aparece varias veces con el mismo standard (distintas ediciones). Con una función de ventana nos quedamos con **una fila por (standard, artista)** — la más temprana. Eso materializa el grano del hecho: *una grabación de un standard por un artista*.

```
-- int_recordings_deduped.sql
row_number() over (
  partition by standard_id, coalesce(artist_id, lower(artist_name))
  order by release_year asc nulls last, track_id
) as rn
... where rn = 1
```

04 Marts: el star schema

Un **esquema en estrella**: la tabla de **hechos** (eventos medibles) en el centro, rodeada de **dimensiones** (el contexto). Las claves entre tablas son **surrogate keys** generadas con `dbt_utils.generate_surrogate_key`.



Modelo	Rol
fct_recordings	Hechos: una grabación (standard x artista). FKs a las 3 dims + medidas de duración.
dim_standards	Título, compositor, año, rank, década.
dim_artists	Nombre, id de Spotify, nº de standards grabados.
dim_years	Año, década y era del jazz (Swing, Bebop, Hard Bop...).

05 Tests: integridad del star schema

24 tests en total. Los más importantes de esta capa son los de **relationships**: verifican que cada clave foránea del hecho apunte a una fila real en su dimensión (como una foreign key). Si un fct_recordings apuntara a un standard inexistente, el build falla.

- **unique + not_null** en cada surrogate key (standard_key, artist_key, year_key, recording_key).
- **relationships**: fct_recordings -> dim_standards, dim_artists, dim_years.

06 Resultados

El embudo del pipeline y la salida de `dbt build`:

```
703 candidatos (stg_recordings)
-> 612 tras entity resolution  (91 falsos positivos filtrados, ~13%)
-> 548 tras deduplicacion      = grano del fact
dims: 100 standards . 371 artistas . 79 años

dbt build: PASS=32 WARN=0 ERROR=0
```

Y lo importante: el modelo produce jazz real. Repertorio más amplio (dim_artists):

Artista	Standards grabados
Ella Fitzgerald	21
Billie Holiday	14

Chet Baker / Frank Sinatra	9
Oscar Peterson	8

07 Limitaciones honestas

release_year es fecha de RELEASE, no de grabación

Spotify suele fechar grabaciones viejas con la fecha de su reedición. Por eso la era "Contemporary" infla. Es era de release, no de grabacion — una distincion que el dashboard debe aclarar.

"Most recorded" esta topeado en 10

La ingesta guardo hasta 10 grabaciones por standard, asi que el conteo refleja ese limite, no el recuento real del canon. Se corrige subiendo el limite de ingesta.

Falsos negativos del match exacto

"I Can't Get Started with You" (sin parentesis) no matchea el standard "... (with You)". Elegimos precision sobre recall: mejor descartar algun valido que colar ruido.

08 Glosario

Término	Qué significa
Star schema	Una tabla de hechos central rodeada de dimensiones. Optimizado para consultas analíticas.
Fact (hecho)	Evento medible. Aca: una grabacion. Lleva claves foraneas y medidas.
Dimension	Contexto descriptivo (standard, artista, anio) que rodea a los hechos.
Grain (grano)	Que representa una fila del hecho. Aca: una grabacion por (standard, artista).
Surrogate key	Clave artificial (un hash) que identifica una fila, en vez de la clave natural.
Entity resolution	Decidir si dos registros refieren a la misma entidad (candidato -> standard real).
Macro	Fragmento de SQL reutilizable en Jinja, como normalize_title.
Materialization	Como se persiste un modelo. Aca: intermediate = view, marts = table.

Siguiente — 05 · Docs & metrics: dbt docs, lineage y metricas (mas grabados, longevidad). · Mathias Berg — Data Analyst -> Analytics Engineer