Paso 05 · Docs & métricas

Documentar el pipeline y medir el canon — dbt docs, lineage y modelos de métricas

Mathias Berg · Stuttgart · 2026-10-02 · Repo: github.com/mbergr/jazz-standards-analytics

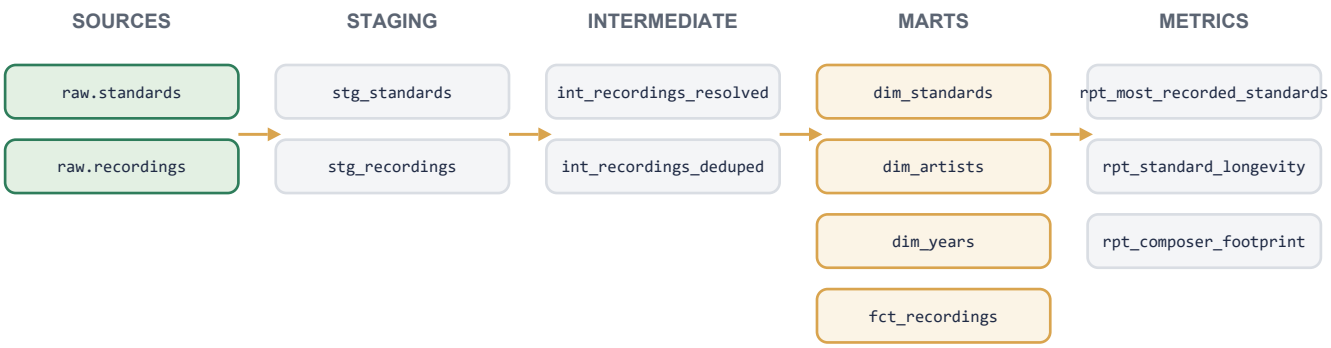
01 Qué construimos

Con el star schema listo, el paso 05 cierra dos cosas: **documentar** todo el pipeline (dbt docs + el grafo de lineage) y **medir** el canon con tres modelos de métricas que responden las preguntas del proyecto.

- **dbt docs** — documentación navegable autogenerada + el grafo de dependencias (lineage).
- **Métricas** — modelos `rpt_` sobre el star schema: más grabados, longevidad y huella de compositor.

02 dbt docs & lineage

`dbt docs generate` construye un catálogo navegable de todos los modelos, columnas y tests. Como cada modelo referencia a sus fuentes con `ref()` y `source()`, dbt deriva el **lineage** automáticamente — el grafo de cómo fluye el dato de punta a punta:



Se genera y se sirve localmente con:

```
cd dbt_project
dbt docs generate --profiles-dir .
dbt docs serve   --profiles-dir .   # abre el sitio navegable
```

03 Los modelos de métricas

Modelo	Qué calcula
rpt_most_recorded_standards	Grabaciones y artistas distintos por standard, rankeado.
rpt_standard_longevity	Primer/último año de grabación, span en años y nº de eras por standard.
rpt_composer_footprint	Standards en el canon, total de grabaciones y rango de años por compositor.

04 Resultados

Más longevos (span de años que se siguió grabando):

Standard	Compuesto	1ª grab.	Última	Span	Eras
Ain't Misbehavin'	1929	1926	2024	98	2
I Got Rhythm	1930	1920	2018	98	4
Sophisticated Lady	1933	1933	2024	91	3
Honeysuckle Rose	1929	1926	2014	88	5

Huella de compositor (top por grabaciones):

Compositor	Standards	Grabaciones
George Gershwin	11	55
Duke Ellington	6	43
Jimmy Van Heusen	4	32
Richard Rodgers	4	24
Cole Porter	4	22

```
dbt build:  PASS=43  WARN=0  ERROR=0   (11 modelos, 32 tests)
```

05 Caveats honestos

La longevidad usa release_year, no fecha de grabación
El span se mide con fechas de release de Spotify. Por reediciones, a veces el "primer anio de grabacion" cae antes del anio de composicion (p.ej. I Got Rhythm: 1920 < 1930). Es ruido de release date, documentado.

"Most recorded" sigue topeado en 10
Heredado de la ingesta (10 grabaciones por standard). El ranking es relativo a lo que se trajo, no al canon real.

Compositores no se separan
La huella agrupa por el string de credito crudo; los temas co-escritos forman su propio grupo.

06 Glosario

Término	Qué significa
dbt docs	Sitio de documentacion autogenerado desde los modelos, columnas y tests.
Lineage	El grafo de dependencias: que fuente alimenta a que modelo, de punta a punta.
catalog.json	Metadata de las tablas/columnas reales en la base, que dbt docs cruza con la doc.
Report model (rpt_)	Modelo de la capa de servicio que agrega hechos+dims en una metrica lista para consumir.
ref() / source()	Funciones con que un modelo referencia a otro modelo o a una fuente; de ahi sale el lineage.

Siguiente — 06 · Dashboard: una app Streamlit que lee los marts/metricas y los visualiza. · Mathias Berg — Data Analyst -> Analytics Engineer